UNIVERSIDAD NACIONAL DEL ALTIPLANO

FACULTAD DE INGENIERÍA MECÁNICA ELÉCTRICA, ELECTRÓNICA Y SISTEMAS

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS



ACTIVIDAD 04: MODELOS DE CLUSTERING LINEAL Y NO LINEAL

Implementación, calibración y validación de K-means, DBSCAN y Spectral Clustering sobre Iris, Two Moons y Two Circles

Curso:	Aprendizaje de Máquina
Docente:	Ing. Fernandez Chambi Mayenka
Integrantes:	Cristian Junior Cunurana Calderon
	Miguel Angel Llusca Surco
	Maria Vanesa Yucra Mendoza
Ciclo:	IX – Grupo B
Periodo:	2026
Entrega:	11 de noviembre de 2026

PUNO – PERÚ
2026

RESUMEN

Esta actividad compara tres familias de algoritmos de clustering —partición (K-means), densidad (DBSCAN) y métodos espectrales (Spectral Clustering)— sobre tres conjuntos de datos con geometrías distintas: Iris (150 muestras, 4 características, tres especies con solapamiento real), Two Moons (500 puntos, dos medias lunas entrelazadas) y Two Circles (500 puntos, dos anillos concéntricos). Cada algoritmo se calibró con barridos documentados de hiperparámetros (regla del codo y curva k-distancia para K-means y DBSCAN; afinidad RBF y k vecinos más cercanos para Spectral Clustering) y se validó con métricas externas (Índice de Rand Ajustado y V-measure, disponibles por el diseño controlado de los experimentos) e internas (silueta, Davies–Bouldin e inercia). Los resultados muestran que en Iris los tres métodos alcanzan acuerdos moderados con la referencia (ARI entre 0.540 y 0.620) por el solapamiento genuino entre *versicolor* y *virginica*; en Moons y Circles, K-means falla (ARI 0.265 y $-0{,}002$) mientras que DBSCAN y Spectral Clustering recuperan la estructura exacta (ARI $= 1{,}0$). El hallazgo central es que las métricas internas favorecen sistemáticamente las particiones **incorrectas** en los datos no convexos: en ambos conjuntos la partición fallida de K-means obtiene mejor silueta y mejor Davies–Bouldin que la partición correcta, e incluso la silueta interna crece al fragmentar las variedades en más grupos. La conclusión práctica es que la elección del algoritmo debe guiarse por la hipótesis geométrica de los datos y no solo por métricas internas, y que la validación externa, cuando existe, es indispensable.

Palabras clave: clustering no supervisado, K-means, DBSCAN, Spectral Clustering, validación externa, métricas internas, geometría no convexa.

ÍNDICE GENERAL

Resumen I

I. Introducción 1

1.1. Contexto . . . 1
1.2. Problema y motivación . . . 1
1.3. Alcance . . . 1
1.4. Estructura del informe . . . 2

II. Objetivos 2

2.1. Objetivo general . . . 2
2.2. Objetivos específicos . . . 2

III. Fundamentos teóricos 3

3.1. Aprendizaje no supervisado y clustering . . . 3
3.2. Dos hipótesis de cluster . . . 3
3.3. Separabilidad lineal geométrica . . . 3
3.4. Validación de particiones . . . 4

IV. Descripción de los algoritmos 4

4.1. K-means: partición por centros . . . 4
4.2. DBSCAN: clustering basado en densidad . . . 4
4.3. Spectral Clustering: grafos de similitud . . . 5
4.4. Comparación formal . . . 5

V. Descripción de las métricas de validación 5

5.1. Métricas externas . . . 5
5.2. Métricas internas . . . 6
5.3. Convenciones adoptadas . . . 7

VI. Metodología experimental 7

6.1. Conjuntos de datos . . . 7
6.2. Preparación de los datos . . . 8
6.3. Protocolo de calibración . . . 8
6.4. Implementación y reproducibilidad . . . 9

VII. Experimento 1: Iris **10**
7.1. Preparación y exploración . . . 10
7.2. Desarrollo: calibración . . . 10
7.3. Resultados . . . 13
7.4. Análisis e interpretación . . . 14

VIII. Experimento 2: Two Moons **14**
8.1. Preparación y exploración . . . 15
8.2. Desarrollo: calibración . . . 15
8.3. Resultados . . . 17
8.4. Análisis e interpretación . . . 17

IX. Experimento 3: Two Circles **18**
9.1. Preparación y exploración . . . 18
9.2. Desarrollo: calibración . . . 18
9.3. Resultados . . . 19
9.4. Análisis e interpretación . . . 20

X. Comparación general de los algoritmos **20**
10.1. Tabla consolidada . . . 20
10.2. Patrones observados . . . 22

XI. Análisis de modelos lineales y no lineales **22**
11.1. Qué es “lineal” en clustering . . . 22
11.2. Evidencia experimental . . . 23
11.3. Por qué los no lineales ganan en variedades . . . 23
11.4. Guía de decisión práctica . . . 23

XII. Hiperparámetros críticos y lecciones de calibración **23**
12.1. K-means: el número de clusters . . . 24
12.2. DBSCAN: ε y `min_samples` . . . 24
12.3. Spectral Clustering: afinidad y sus parámetros . . . 24
12.4. Sensibilidad resumida . . . 24

XIII. Conclusiones y trabajo futuro **25**
13.1. Conclusiones . . . 25
13.2. Trabajo futuro . . . 25

Repositorio del proyecto **26**

Referencias **26**

ÍNDICE DE FIGURAS

VII.1. Iris: datos originales proyectados sobre las dos primeras componentes principales (espacio de visualización, no de entrenamiento). Fuente: notebook, celda 05.1. . . . 10

VII.2. Iris: regla del codo para K-means (inercia y silueta por k). Fuente: notebook, celda 05.2. . . . 11

VII.3. Iris: curva k-distancia ($m = 5$) con la rodilla marcada en $\varepsilon \approx 0{,}757$. Fuente: notebook, celda 05.7. . . . 11

VII.4. Iris: matriz de similitud RBF ($\gamma = 2{,}0$) reordenada según los clusters. Fuente: notebook, celda 05.11. . . . 13

VII.5. Iris: particiones obtenidas por los tres algoritmos frente a la referencia (proyección PCA). Fuente: notebook, celda 05.13. . . . 13

VII.6. Iris: métricas externas e internas de los tres modelos. Fuente: notebook, celda 05.14. . . . 14

VIII.1. Moons: curva k-distancia ($m = 5$) con la rodilla marcada en $\varepsilon \approx 0{,}108$. Fuente: notebook, celda 06.6. . . . 15

VIII.2. Moons: referencia y particiones de los tres algoritmos. Fuente: notebook, celda 06.11. . . . 17

VIII.3. Moons: métricas externas e internas de los tres modelos. Fuente: notebook, celda 06.12. . . . 17

IX.1. Circles: curva k-distancia ($m = 5$) con la rodilla marcada en $\varepsilon \approx 0{,}126$. Fuente: notebook, celda 07.6. . . . 18

IX.2. Circles: referencia y particiones de los tres algoritmos. Fuente: notebook, celda 07.11. . . . 19

IX.3. Circles: métricas externas e internas de los tres modelos. Fuente: notebook, celda 07.12. . . . 20

X.1. Comparación general de métricas entre los tres algoritmos en los tres datasets. Fuente: notebook, celda 08.1. . . . 21

X.2. Índice de Rand Ajustado por dataset y algoritmo. Fuente: notebook, celda 08.2. 22

ÍNDICE DE TABLAS

IV.1. Comparación conceptual de los tres algoritmos implementados. 5

V.1. Resumen de las métricas de validación empleadas. 7

VI.1. Conjuntos de datos utilizados. 8
VI.2. Configuraciones finales por dataset y criterio de selección. 9

VII.1. Iris: inercia y silueta de K-means por número de clusters k. 11
VII.2. Iris: barrido de DBSCAN con `min_samples`$= 5$ (métricas internas calculadas sin el ruido). 12
VII.3. Iris: barrido de Spectral Clustering ($k = 3$ salvo indicación). "Grafo" indica conectividad completa. 12
VII.4. Iris: métricas finales de los tres modelos. 14

VIII.1. Moons: barrido de DBSCAN con `min_samples`$= 5$. 16
VIII.2. Moons: barrido de Spectral Clustering ($k = 2$). 16
VIII.3. Moons: métricas finales de los tres modelos. 17

IX.1. Circles: barrido de DBSCAN con `min_samples`$= 5$. 19
IX.2. Circles: barrido de Spectral Clustering ($k = 2$). 19
IX.3. Circles: métricas finales de los tres modelos. 20

X.1. Resumen general de los nueve modelos finales (semilla 42). 21

XII.1. Sensibilidad observada de los hiperparámetros. 24

CAPÍTULO I

INTRODUCCIÓN

1.1 Contexto

El aprendizaje automático se divide en dos grandes regímenes según la información disponible durante el entrenamiento. En el aprendizaje supervisado cada observación llega acompañada de una etiqueta y el objetivo es aprender una función que la prediga. En el aprendizaje no supervisado, en cambio, solo se observan las características de los datos y el objetivo es descubrir organización interna: grupos, estructuras, variedades o densidades. El **clustering** o agrupamiento es la tarea canónica de ese segundo régimen: dado una matriz de datos $X \in \mathbb{R}^{n \times d}$, se busca una partición de los n puntos en grupos tales que los puntos de un mismo grupo sean similares entre sí y los de grupos distintos sean disímiles.

A diferencia de la clasificación, el clustering no tiene una única respuesta correcta: lo que cuenta como "buen grupo" depende de la hipótesis geométrica que el algoritmo asume. Algunos métodos definen los grupos por **compactión** (regiones convexas y densas alrededor de un centro); otros los definen por **conectividad** (puntos unidos por caminos densos o por aristas de un grafo de similitud). Sobre datos con forma de "bola" ambas hipótesis coinciden; sobre datos con forma de media luna, anillo o espiral divergen por completo. Esta actividad estudia esa divergencia de manera controlada.

1.2 Problema y motivación

En la práctica es frecuente elegir un algoritmo de clustering por costumbre o por la métrica interna que maximiza, sin verificar si su hipótesis geométrica es compatible con la estructura de los datos. Eso produce particiones que *parecen* buenas según indicadores internos pero que rompen la estructura real de los datos. El problema que motiva esta actividad es, entonces, doble: (i) entender qué hace geométricamente cada familia de algoritmos y (ii) establecer qué métricas de validación son confiables y en qué condiciones.

Para estudiarlo de forma controlada se emplean tres conjuntos de datos con geometría crecientemente hostil para los métodos lineales: Iris, con grupos mayormente compactos y un solapamiento real entre dos especies; Two Moons, dos variedades no convexas entrelazadas; y Two Circles, dos anillos concéntricos que comparten centroide. Sobre ellos se ejecutan tres algoritmos representativos: K-means (partición por centros), DBSCAN (densidad) y Spectral Clustering (grafos de similitud).

1.3 Alcance

La actividad cubre la implementación y calibración de los tres algoritmos en los tres conjuntos de datos, la comparación con métricas externas (Índice de Rand Ajustado y V-measure) e internas (silueta, Davies–Bouldin, inercia), el análisis de sensibilidad a los hiperparámetros y

una comparación general. Las etiquetas reales se usan **exclusivamente** para validación externa, nunca para entrenar o ajustar los modelos. Todos los resultados numéricos y las figuras de este informe provienen del notebook `Actividad_04_Clustering.ipynb`, ejecutado con semilla 42 sobre scikit-learn 1.9.1.

1.4 Estructura del informe

El Capítulo II presenta los objetivos. El Capítulo III desarrolla los fundamentos teóricos. Los Capítulos IV y V describen los algoritmos y las métricas. El Capítulo VI detalla la metodología experimental. Los Capítulos VII, VIII y IX presentan el desarrollo y los resultados en Iris, Moons y Circles. El Capítulo X consolida la comparación general; el Capítulo XI analiza el comportamiento lineal frente al no lineal; el Capítulo XII estudia los hiperparámetros críticos. El Capítulo XIII cierra con las conclusiones, seguido del repositorio del proyecto y las referencias.

CAPÍTULO II

OBJETIVOS

2.1 Objetivo general

Implementar, calibrar y comparar de forma experimental tres modelos de clustering lineal y no lineal —K-means, DBSCAN y Spectral Clustering— sobre tres conjuntos de datos con geometría controlada (Iris, Two Moons y Two Circles), validándolos con métricas externas e internas para establecer qué algoritmo conviene según la hipótesis geométrica de los datos y qué tan confiables son las métricas de validación en cada caso.

2.2 Objetivos específicos

1. Implementar en un notebook reproducible la carga y preparación de los tres conjuntos de datos, documentando las transformaciones aplicadas.
2. Implementar desde *scikit-learn* los tres algoritmos de clustering con sus hiperparámetros principales.
3. Calibrar K-means con la regla del codo y la silueta; DBSCAN con la curva k-distancia y un barrido documentado de $(\varepsilon, \text{min_samples})$; Spectral Clustering con barridos de afinidad RBF y k vecinos más cercanos.
4. Evaluar todas las particiones con métricas externas (ARI, V-measure) e internas (silueta, Davies–Bouldin), adoptando convenciones explícitas para el ruido de DBSCAN y para los casos no definibles.
5. Comparar el comportamiento de los tres algoritmos en datos convexos y no convexos, identificando el papel del sesgo geométrico de cada método y de cada métrica.
6. Analizar la sensibilidad de los resultados a los hiperparámetros críticos y derivar lecciones prácticas de calibración.
7. Redactar un informe LaTeX con los resultados y preparar el material para su publicación en un repositorio GitHub.

CAPÍTULO III

FUNDAMENTOS TEÓRICOS

3.1 Aprendizaje no supervisado y clustering

Dado $X = \{x_1, \ldots, x_n\} \subset \mathbb{R}^d$, el clustering busca una función $f : X \to \{1, \ldots, k\}$ que asigne cada punto a un grupo. Sin etiquetas, no existe una función de pérdida observable y la calidad se define por criterios internos de la partición: compactación intra-grupo, separación inter-grupo, estabilidad o verosimilitud bajo un modelo generativo. Esa libertad hace que el clustering sea, en esencia, una tarea **mal planteada** (ill-posed) salvo que se fije de antemano una definición de "grupo" [10].

3.2 Dos hipótesis de cluster

La literatura distingue dos grandes definiciones operativas de cluster [10]:

- **Hipótesis de compactación:** un cluster es una región densa y *convexa* alrededor de un prototipo (centroide o medoide). Los puntos de un mismo cluster están cerca de un centro común. K-means es su encarnación canónica; el clustering basado en modelos de mezcla gaussiana pertenece a la misma familia.
- **Hipótesis de conectividad:** un cluster es un conjunto de puntos conectados por caminos de alta densidad o por aristas de un grafo de similitud. La forma del grupo puede ser arbitraria (media luna, anillo, espiral). DBSCAN (densidad) y Spectral Clustering (grafos) son sus representantes.

Cuando los datos cumplen ambas hipótesis a la vez —grupos convexos, separados y de escala similar— los tres algoritmos convergen a particiones parecidas. Cuando solo cumple la segunda, los métodos de compactación fallan de forma estructural, no numérica: el mínimo de su función objetivo *es* una mala partición.

3.3 Separabilidad lineal geométrica

En clasificación, la separabilidad lineal se refiere a la existencia de un hiperplano que separa clases. En clustering, el análogo es la existencia de una partición cuyos grupos sean separables por fronteras lineales entre prototipos: el diagrama de Voronoi de los centroides de K-means define exactamente fronteras lineales a tramos. Diremos que un conjunto de datos es **linealmente agrupable** cuando su estructura coincide con una descomposición en celdas convexas de Voronoi, y **no linealmente agrupable** cuando la frontera natural entre grupos es curva o topológica. Two Moons y Two Circles son los casos canónicos del segundo tipo: cualquier corte por hiperplanos mezcla ambos grupos.

3.4 Validación de particiones

Las métricas de validación se dividen en dos familias. Las **externas** comparan la partición obtenida con una referencia (etiquetas verdaderas o un agrupamiento de consenso); miden acuerdo, no geometría. Las **internas** evalúan la partición usando solo los datos: compactación, separación y consistencia. La tesis que esta actividad pone a prueba experimentalmente es que las métricas internas están correlacionadas con la hipótesis de compactación: miden convexidad y separación de centros, no conectividad. Por ello, en datos no convexos pueden calificar como "mejores" particiones estructuralmente incorrectas.

Idea central del experimento

Si la geometría de los datos contradice la hipótesis del algoritmo, el algoritmo fallará; si contradice la hipótesis de la métrica, la métrica mentirá. Ambos efectos se observan y cuantifican en los Capítulos VIII y IX.

CAPÍTULO IV

DESCRIPCIÓN DE LOS ALGORITMOS

4.1 K-means: partición por centros

K-means [5] minimiza la inercia o suma de distancias cuadradas intra-grupo,

$$J = \sum_{j=1}^{k} \sum_{x_i \in C_j} \|x_i - \mu_j\|^2, \qquad \mu_j = \frac{1}{|C_j|} \sum_{x_i \in C_j} x_i, \tag{IV.1}$$

mediante el algoritmo de Lloyd: asignar cada punto al centroide más cercano, recomputar centroides y repetir hasta convergencia. La frontera entre dos clusters es el hiperplano equidistante entre sus centroides, de modo que la partición final es una teselación de Voronoi: **regiones convexas**. Sus hiperparámetros son el número de clusters k (obligatorio y fijo) y la inicialización (`n_init`, semilla). Sus supuestos geométricos son grupos convexos, de tamaño y escala parecidos; falla de forma estructural en variedades no convexas y en clusters de densidad distinta.

4.2 DBSCAN: clustering basado en densidad

DBSCAN [2] clasifica los puntos en tres tipos. Un punto es **núcleo** si su bola de radio ε contiene al menos `min_samples` puntos; es **frontera** si no es núcleo pero cae en la bola de un núcleo; y es **ruido** en caso contrario. Un cluster es entonces un conjunto maximal de puntos densamente alcanzables entre sí. Como la pertenencia se define por densidad local y no por distancia a un centro, los clusters pueden tener forma arbitraria y el ruido se detecta explícitamente (etiqueta -1). Sus hiperparámetros críticos son ε y `min_samples`; el número de clusters es un *resultado*, no un parámetro. Sus debilidades son la sensibilidad a ε y la dificultad con clusters de densidades muy distintas, además del costo de los vecinos en alta dimensión.

4.3 Spectral Clustering: grafos de similitud

Spectral Clustering [6, 10] no agrupa los puntos directamente: construye un grafo de similitud $G = (V, E)$, donde cada punto es un vértice y las aristas ponderan la similitud (por kernel gaussiano RBF, $w_{ij} = \exp(-\gamma\|x_i - x_j\|^2)$, o por los k vecinos más cercanos). A partir de la matriz de adyacencia W se forma el Laplaciano normalizado $L = I - D^{-1/2}WD^{-1/2}$ y se calculan los k autovectores asociados a los k autovalores más pequeños. La matriz de autovectores $U \in \mathbb{R}^{n\times k}$, con filas normalizadas, define una incrustación en la que los grupos conectados del grafo se vuelven separables linealmente; se ejecuta K-means sobre esas filas. La clave es que **la afinidad codifica la geometría esperada**: RBF premia cercanía euclidiana (compactación), mientras que k vecinos preserva conectividad local (variedades). Sus hiperparámetros son la afinidad, sus parámetros (γ o k de vecinos) y el número de clusters.

4.4 Comparación formal

La Tabla IV.1 resume las tres familias.

Tabla IV.1: Comparación conceptual de los tres algoritmos implementados.

Algoritmo	Familia	Hipótesis geométrica	Hiperparámetros
K-means	Partición	Compactación: grupos convexos, isotrópicos y de escala similar; fronteras lineales de Voronoi.	k (`n_clusters`), `n_init`, semilla.
DBSCAN	Densidad	Conectividad: regiones de densidad uniforme separadas por zonas dispersas; formas arbitrarias y ruido explícito.	ε (`eps`), `min_samples`.
Spectral	Grafo	Conectividad por similitud: grupos = componentes/cortes del grafo de afinidad; la afinidad define la geometría.	afinidad (RBF/kNN), γ o vecinos, k.

CAPÍTULO V

DESCRIPCIÓN DE LAS MÉTRICAS DE VALIDACIÓN

5.1 Métricas externas

Las métricas externas comparan la partición obtenida $\hat{y}$ con la referencia y. Se usan porque los tres conjuntos de datos tienen etiquetas disponibles *por diseño experimental*; en un problema real no supervisado no existirían.

5.1.1 Índice de Rand Ajustado (ARI)

El Índice de Rand cuenta la proporción de pares de puntos clasificados de forma consistente (juntos o separados) en ambas particiones. El ARI [4] corrige ese valor por el acuerdo esperado al azar:

$$\mathrm{ARI} = \frac{\mathrm{RI} - E[\mathrm{RI}]}{\max(\mathrm{RI}) - E[\mathrm{RI}]}, \tag{V.1}$$

de modo que ARI $= 1$ indica particiones idénticas, ARI $= 0$ acuerdo equivalente al azar y valores negativos, acuerdo peor que el azar (solo posible tras el ajuste). Es simétrico: no premia más etiquetas.

5.1.2 V-measure (homogeneidad y completitud)

La V-measure [8] es la media armónica de dos entropías condicionales: **homogeneidad** (h: cada cluster contiene una sola clase) y **completitud** (c: cada clase está en un solo cluster). Toma valores en $[0, 1]$, con 1 en la coincidencia perfecta. A diferencia del ARI, su asimetría h/c es diagnóstica: revela *cómo* falla una partición (fragmentación frente a fusión).

5.2 Métricas internas

Las métricas internas no requieren referencia y son las únicas disponibles en un problema genuinamente no supervisado.

5.2.1 Silueta

Para cada punto i con $a(i)$ = distancia media a su propio cluster y $b(i)$ = distancia media al cluster vecino más próximo, la silueta [9] es

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1]. \tag{V.2}$$

Valores cercanos a 1 indican puntos bien embebidos; cercanos a 0, frontera; negativos, mal asignados. La silueta premia clusters compactos y **convexos**.

5.2.2 Davies–Bouldin

El índice Davies–Bouldin [1] promedia, para cada cluster, la peor razón entre la dispersión intra-cluster y la separación entre centroides:

$$\mathrm{DBI} = \frac{1}{k} \sum_{i=1}^{k} \max_{j \neq i} \frac{\bar{d}_i + \bar{d}_j}{\|\mu_i - \mu_j\|}. \tag{V.3}$$

Valores menores son mejores (DBI $= 0$ sería la separación ideal). Depende de los **centroides**: si dos grupos comparten centroide —dos anillos concéntricos, por ejemplo— el denominador se aproxima a cero y el índice explota aunque la partición sea la correcta.

5.2.3 Regla del codo (inercia)

Para K-means se grafica la inercia J en función de k; la zona donde la pendiente cae bruscamente (el "codo") sugiere el número natural de grupos. Es un criterio gráfico y subjetivo que conviene cruzar con la silueta y con conocimiento del dominio.

5.3 Convenciones adoptadas

Convenciones de evaluación

- **Ruido de DBSCAN:** los puntos con etiqueta -1 se *excluyen* del cálculo de silueta y Davies–Bouldin (no forman parte de ningún grupo), pero se *incluyen* como una "clase" más en ARI y V-measure, porque en la comparación externa todo punto debe estar clasificado.
- **Casos no definibles:** si una partición produce $k < 2$ clusters efectivos (o $k \geq n$), la silueta y Davies–Bouldin quedan sin definir; se registran como NaN y se documentan, nunca como cero.
- **Etiquetas reales:** se usan exclusivamente para validación externa; ningún algoritmo las consume en entrenamiento.
- **Reproducibilidad:** semilla global 42, `n_init`=10, figuras a 300 dpi y métricas exportadas a `resultados/`.

La Tabla V.1 resume las seis métricas.

Tabla V.1: Resumen de las métricas de validación empleadas.

Métrica	Tipo	Rango	Qué mide / mejor valor
ARI	Externa	$[-1, 1]$	Acuerdo de pares con corrección por azar; 1 = idéntico, 0 = azar.
V-measure	Externa	$[0, 1]$	Media armónica de homogeneidad y completitud; 1 = coincidencia.
Silueta	Interna	$[-1, 1]$	Cohesión frente a separación local; mayor es mejor.
Davies–Bouldin	Interna	$[0, \infty)$	Dispersión intra frente a separación de centroides; menor es mejor.
Inercia (codo)	Interna	$[0, \infty)$	Suma de cuadrados intra-cluster de K-means; criterio gráfico de k.

CAPÍTULO VI

METODOLOGÍA EXPERIMENTAL

6.1 Conjuntos de datos

La Tabla VI.1 describe los tres conjuntos. Fueron elegidos para cubrir un espectro de dificultad geométrica creciente para los métodos de partición: compactación aproximada (Iris), variedad no convexa (Moons) y estructura topológica anidada (Circles).

Tabla VI.1: Conjuntos de datos utilizados.

Dataset	Tamaño	Dimensiones	Naturaleza	Uso de y
Iris [3]	150	4 características reales	Tres especies de flor; *setosa* separable, *versicolor* y *virginica* solapadas.	Validación externa.
Two Moons	500	2 coordenadas	Dos medias lunas entrelazadas, ruido gaussiano $\sigma = 0{,}1$.	Validación externa.
Two Circles	500	2 coordenadas	Dos anillos concéntricos (razón de radios 0.4), ruido $\sigma = 0{,}08$.	Validación externa.

6.2 Preparación de los datos

Iris se **estandarizó** (media cero, varianza uno por característica) antes de agrupar, porque sus cuatro medidas están en escalas distintas y todos los algoritmos usados dependen de distancias euclidianas. Sobre los datos estandarizados se entrenaron los modelos; un análisis de componentes principales (PCA a 2 dimensiones) se usó *únicamente* para visualizar los resultados, nunca como espacio de entrenamiento. Moons y Circles se generaron ya en un espacio 2D homogéneo con `make_moons` y `make_circles` (parámetros en la Tabla VI.1) y se usaron sin reescalado, para no alterar las escalas de densidad con las que se calibra DBSCAN.

6.3 Protocolo de calibración

Cada algoritmo se calibró por barrido documentado antes de la ejecución final:

- **K-means:** curva de codo (inercia y silueta para $k = 1 \dots 10$ en Iris; $k = 1 \dots 8$ en Moons y Circles) y decisión guiada por el diseño del generador.
- **DBSCAN:** gráfico k-distancia (distancia de cada punto a su m-ésimo vecino, ordenada) para localizar la "rodilla" que sugiere ε; después barrido de $(\varepsilon, \texttt{min_samples})$ con registro de número de clusters, ruido y métricas internas.
- **Spectral Clustering:** barrido de afinidad RBF (γ creciente) y de k vecinos más cercanos, verificando en cada caso la conectividad del grafo.

La Tabla VI.2 resume las configuraciones finales seleccionadas y el criterio aplicado.

Tabla VI.2: Configuraciones finales por dataset y criterio de selección.

Datos	Configuración final	Barrido explorado	Criterio
Iris	K-means, $k = 3$	$k = 1 \dots 10$	Codo en $k = 3$; coincide con las tres especies.
Iris	DBSCAN, $\varepsilon = 0{,}7$, $m = 5$	$\varepsilon \in [0{,}4, 1{,}2]$, $m \in \{4, 5, 10\}$	Rodilla k-distancia $\approx 0{,}757$; ruido $< 5\,\%$ y silueta alta.
Iris	Spectral, RBF $\gamma = 2{,}0$, $k = 3$	RBF γ: 0.25, 0.5, 1, 2, 5; kNN: 5, 10, 15	Mejor silueta interna con grafo conectado, antes de saturar.
Moons	K-means, $k = 2$	$k = 1 \dots 8$	Mayor caída de inercia en $k = 2$; diseño del generador.
Moons	DBSCAN, $\varepsilon = 0{,}2$, $m = 5$	$\varepsilon \in [0{,}08, 0{,}30]$, $m \in \{5, 10\}$	Rodilla $\approx 0{,}108$; $k = 2$ y ruido $0\,\%$.
Moons	Spectral, kNN $k = 10$, $k = 2$	RBF γ: 1, 5, 10, 30, 100; kNN: 5, 10, 15	Robustez: misma partición para 5–15 vecinos.
Circles	K-means, $k = 2$	$k = 1 \dots 8$	Codo en $k = 2$; diseño del generador.
Circles	DBSCAN, $\varepsilon = 0{,}2$, $m = 5$	$\varepsilon \in [0{,}08, 0{,}30]$, $m \in \{5, 10\}$	Rodilla $\approx 0{,}126$; $k = 2$ y ruido $0\,\%$.
Circles	Spectral, kNN $k = 10$, $k = 2$	RBF γ: 1, 5, 10, 30, 100; kNN: 5, 10, 15	Robustez en vecinos; geometría anular requiere conectividad.

6.4 Implementación y reproducibilidad

Todo el desarrollo se realizó en el notebook `Actividad_04_Clustering.ipynb` con Python 3.14, scikit-learn 1.9.1, numpy 2.5.4, pandas 3.0.6 y matplotlib 3.11.2. La evaluación centraliza las métricas en una función única que aplica las convenciones del Capítulo V; el fragmento VI.1 muestra su núcleo.

Listing VI.1: Núcleo de la función de evaluación de particiones.

```
def evaluar_particion(X, y_reales, etiquetas):
    """Metricas externas (ARI, V-measure) e internas (sil, DBI)."""
    k, ruido = contar_clusters_ruido(etiquetas)
    ari = adjusted_rand_score(y_reales, etiquetas)
    v   = v_measure_score(y_reales, etiquetas)
    # silueta/DBI solo sobre puntos asignados (sin ruido -1)
    mascara = etiquetas != -1
    if k >= 2 and mascara.sum() > k:
        sil = silhouette_score(X[mascara], etiquetas[mascara])
        dbi = davies_bouldin_score(X[mascara], etiquetas[mascara])
    else:
        sil, dbi = np.nan, np.nan   # caso no definible, documentado
    return dict(k=k, ruido=ruido, ARI=ari, V=v, Sil=sil, DBI=dbi)
```

Cada experimento guarda sus métricas en `resultados/metricas/` (CSV) y sus figuras en `re-`

`sultados/graficas/` (PNG a 300 dpi); la Tabla X.1 del Capítulo X consolida los nueve modelos finales. La ejecución completa del notebook dura alrededor de un minuto en un portátil convencional y no requiere GPU.

CAPÍTULO VII

EXPERIMENTO 1: IRIS

7.1 Preparación y exploración

Iris contiene 150 flores (50 por especie) descritas por largo y ancho de sépalo y pétalo. Tras estandarizar, el PCA de visualización (Figura VII.1) muestra la geometría del problema: *setosa* forma un grupo compacto y aislado, mientras que *versicolor* y *virginica* se solapan en una franja central. Ningún algoritmo que use solo las cuatro características puede separar ese solapamiento de forma perfecta: el techo de ARI es estructural, no algorítmico.

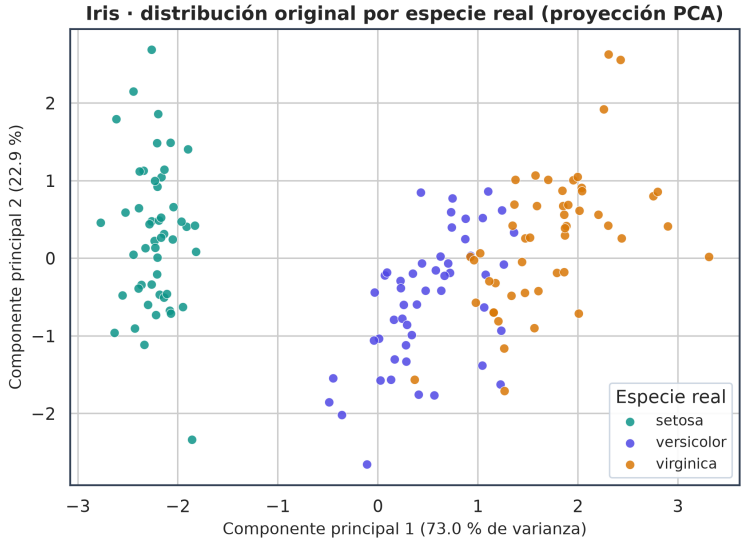


Figura VII.1: Iris: datos originales proyectados sobre las dos primeras componentes principales (espacio de visualización, no de entrenamiento). Fuente: notebook, celda 05.1.

7.2 Desarrollo: calibración

7.2.1 K-means: regla del codo

La Figura VII.2 y la Tabla VII.1 muestran la inercia y la silueta para $k = 1 \ldots 10$. La inercia cae fuertemente hasta $k = 3$ (600.0 $\rightarrow$ 222.4 $\rightarrow$ 139.8) y luego desciende suavemente: el codo está en $k = 3$. La silueta, en cambio, prefiere $k = 2$ (0.582): fusionar *versicolor* y *virginica* en un solo cluster produce grupos más compactos. Se elige $k = 3$ por el codo y por el conocimiento del dominio (tres especies), documentando la discrepancia como un primer síntoma del sesgo de compactación de las métricas internas.

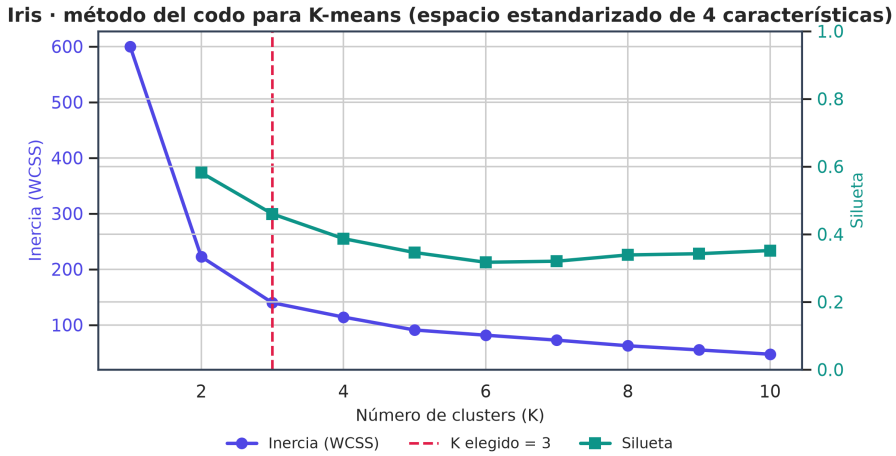


Figura VII.2: Iris: regla del codo para K-means (inercia y silueta por k). Fuente: notebook, celda 05.2.

Tabla VII.1: Iris: inercia y silueta de K-means por número de clusters k.

k	1	2	3	4	5	6	7	8	9	10
Inercia	600.0	222.4	**139.8**	114.1	90.9	81.5	72.6	62.5	55.1	47.4
Silueta	—	**0.582**	0.460	0.387	0.346	0.317	0.320	0.339	0.342	0.352

7.2.2 DBSCAN: curva k-distancia y barrido

La Figura VII.3 ordena la distancia de cada punto a su quinto vecino más cercano; la rodilla (cambio brusco de pendiente) aparece en $\varepsilon \approx 0{,}76$, valor que delimita la zona de "densidad normal" de la zona de transición hacia el ruido. La Tabla VII.2 muestra el barrido con `min_samples`$= 5$ (los barridos con $m = 4$ y $m = 10$ siguen el mismo patrón y están en el notebook). Con ε pequeño el dataset se fragmenta en 5–6 clusters y más del 40 %de los puntos se marca como ruido; a partir de $\varepsilon \approx 0{,}7$ la partición se estabiliza en 2 clusters con ruido decreciente. Se selecciona $\varepsilon = 0{,}7$, $m = 5$: ruido de 6 puntos (4 %), silueta 0.602 y DBI 0.557.

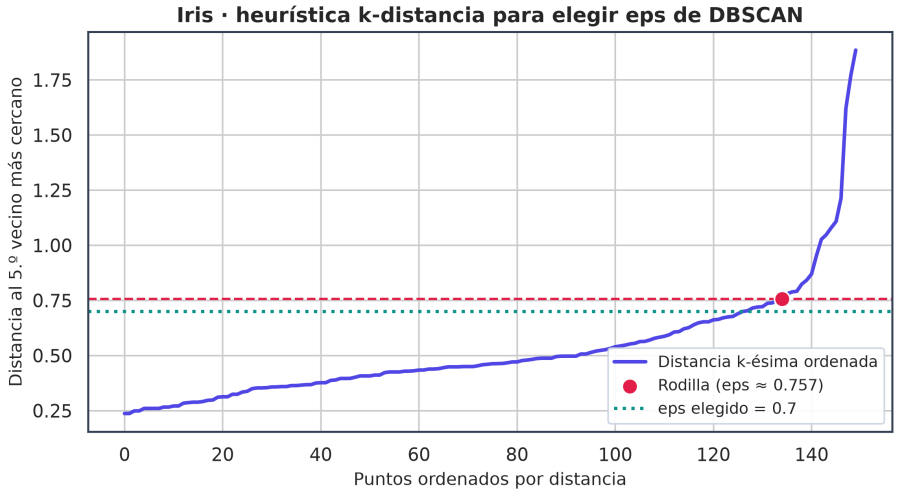


Figura VII.3: Iris: curva k-distancia ($m = 5$) con la rodilla marcada en $\varepsilon \approx 0{,}757$. Fuente: notebook, celda 05.7.

Tabla VII.2: Iris: barrido de DBSCAN con `min_samples`$= 5$ (métricas internas calculadas sin el ruido).

ε	Clusters	Ruido	Ruido (%)	Silueta	Davies–Bouldin
0.4	6	66	44.0	0.486	0.786
0.5	2	34	22.7	0.656	0.494
0.6	2	26	17.3	0.642	0.512
0.7	**2**	**6**	**4.0**	**0.602**	**0.557**
0.8	2	4	2.7	0.598	0.569
1.0	2	3	2.0	0.595	0.571
1.2	2	1	0.7	0.587	0.580

7.2.3 Spectral Clustering: afinidad y matriz de similitud

La Tabla VII.3 resume el barrido de afinidades. Con RBF, la silueta sube de 0.460 ($\gamma = 0{,}25$) a 0.495 ($\gamma = 2{,}0$) y se estanca en $\gamma = 5$; con k vecinos, $k = 5$ deja el grafo desconectado y $k = 10$–15 producen siluetas menores. La Figura VII.4 muestra la matriz de similitud RBF reordenada por cluster para $\gamma = 2{,}0$: se distinguen los bloques diagonales, en especial el bloque nítido de *setosa*. Se selecciona RBF con $\gamma = 2{,}0$ y $k = 3$.

Tabla VII.3: Iris: barrido de Spectral Clustering ($k = 3$ salvo indicación). "Grafo" indica conectividad completa.

Afinidad	Grafo	Clusters	Silueta	Davies–Bouldin
RBF, $\gamma = 0{,}25$	Sí	3	0.460	0.831
RBF, $\gamma = 0{,}5$	Sí	3	0.460	0.831
RBF, $\gamma = 1{,}0$	Sí	3	0.463	0.826
RBF, $\gamma = 2{,}0$	**Sí**	**3**	**0.495**	**0.534**
RBF, $\gamma = 5{,}0$	Sí	3	0.495	0.534
kNN, 5 vecinos	No	3	0.495	0.653
kNN, 10 vecinos	Sí	3	0.459	0.822
kNN, 15 vecinos	Sí	3	0.463	0.832
kNN, 10 vecinos ($k = 2$)	Sí	2	0.582	0.593
kNN, 10 vecinos ($k = 4$)	Sí	4	0.389	0.837

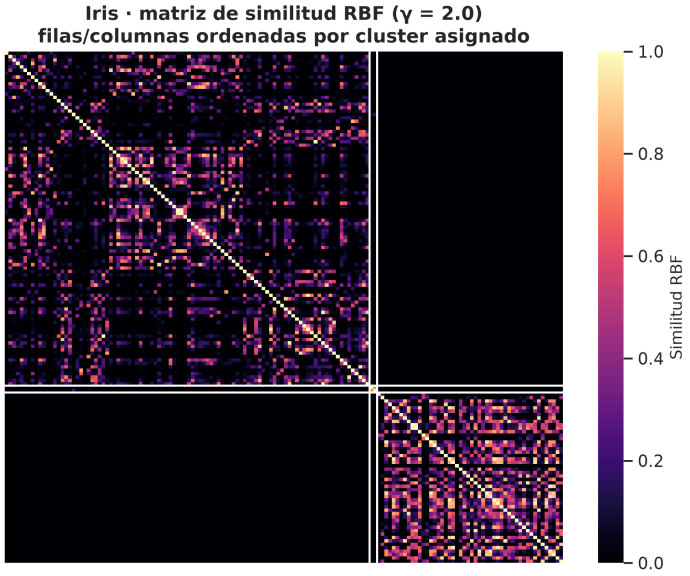


Figura VII.4: Iris: matriz de similitud RBF ($\gamma = 2{,}0$) reordenada según los clusters. Fuente: notebook, celda 05.11.

7.3 Resultados

La Figura VII.5 juxtapone la verdad de referencia y las tres particiones; la Tabla VII.4 consolida las métricas y la Figura VII.6 las grafica.

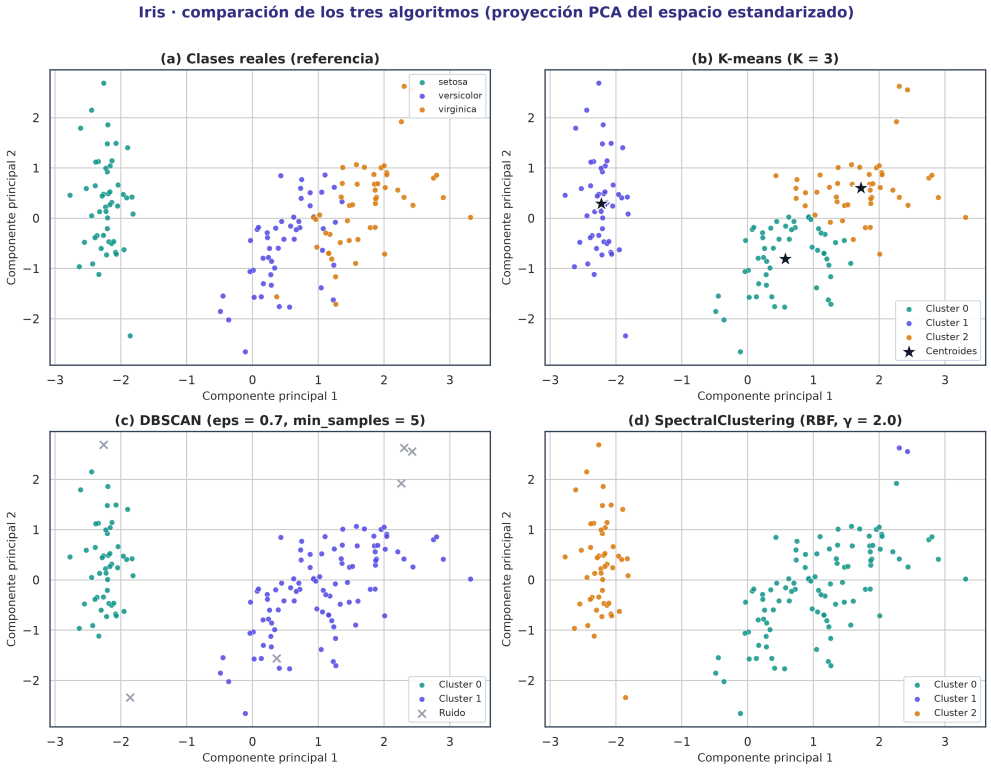


Figura VII.5: Iris: particiones obtenidas por los tres algoritmos frente a la referencia (proyección PCA). Fuente: notebook, celda 05.13.

Tabla VII.4: Iris: métricas finales de los tres modelos.

Modelo	Configuración	k	Ruido	ARI	V-measure	Silueta	DBI
K-means	$k = 3$, `n_init=10`	3	0	**0.620**	0.659	0.460	0.834
DBSCAN	$\varepsilon = 0{,}7$, $m = 5$	2	6	0.540	0.671	**0.602**	**0.557**
Spectral	RBF, $\gamma = 2{,}0$	3	0	0.564	**0.717**	0.495	0.534

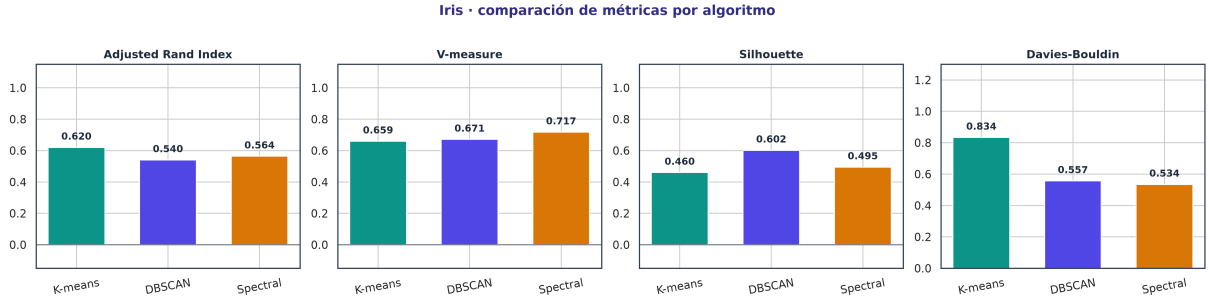


Figura VII.6: Iris: métricas externas e internas de los tres modelos. Fuente: notebook, celda 05.14.

7.4 Análisis e interpretación

Las contingencias por especie explican las métricas. K-means aísla las 50 *setosa* en un cluster puro y reparte las otras dos especies en dos clusters mixtos (39/14 y 11/36 entre *versicolor*/*virginica*): homogeneidad 0.659, completitud 0.660. DBSCAN, con $\varepsilon = 0{,}7$, forma un cluster de 48 *setosa*, un cluster que funde *versicolor* con *virginica* (50+46) y 6 puntos de ruido (2 *setosa* y 4 *virginica*): su homogeneidad baja a 0.574, pero su completitud sube a 0.809 porque no fragmenta las clases. Spectral con $\gamma = 2{,}0$ aísla también las 50 *setosa* y reparte el resto en un cluster mixto de 98 puntos y uno pequeño de 2 *virginica*: homogeneidad 0.588, completitud 0.920, la V-measure más alta (0.717).

Lectura del experimento 1

En Iris **ningún algoritmo domina**: K-means gana en ARI (0.620), Spectral en V-measure (0.717) y DBSCAN en silueta (0.602) y DBI (0.557). El acuerdo moderado con la referencia (ARI entre 0.54 y 0.62) no es un fallo de calibración sino el reflejo del solapamiento real entre *versicolor* y *virginica*. Las estrategias frente a ese solapamiento difieren: K-means lo corta por la mitad, DBSCAN lo funde y expulsa los puntos más ambiguos como ruido, y Spectral lo recorta suavemente por densidad de similitud. Además, la métrica interna (silueta) y la externa (ARI) **discrepan en el ranking**: la primera premia la partición de 2 clusters de DBSCAN, la segunda la de 3 de K-means.

CAPÍTULO VIII

EXPERIMENTO 2: TWO MOONS

8.1 Preparación y exploración

Two Moons contiene 500 puntos en dos medias lunas entrelazadas (ruido gaussiano $\sigma = 0{,}1$, 250 puntos por luna). La estructura es no convexa por diseño: cada luna es una variedad curva y ambas se interpenetran en el plano, de modo que ninguna frontera lineal puede separarlas. La Figura VIII.2 (panel a) muestra la distribución original.

8.2 Desarrollo: calibración

8.2.1 K-means

La caída de inercia de $k = 1$ a $k = 2$ es la más pronunciada ($511.4 \rightarrow 209.6$) y la curva se aplana después: el codo está en $k = 2$, coherente con el generador. Cabe notar que la silueta *crece* con k en este dataset (hasta 0.512 con $k = 6$): trocear las lunas en más grupos convexos la maximiza — primer síntoma del sesgo que domina este experimento. Se entrena con $k = 2$.

8.2.2 DBSCAN

La curva k-distancia (Figura VIII.1) marca la rodilla en $\varepsilon \approx 0{,}108$. La Tabla VIII.1 muestra el barrido con $m = 5$: por debajo de la rodilla el dataset se fragmenta (19 clusters y 18 %de ruido con $\varepsilon = 0{,}08$); en la banda $[0{,}12, 0{,}25]$ la partición se estabiliza en exactamente 2 clusters con ruido decreciente; y con $\varepsilon \geq 0{,}30$ las dos lunas se funden en un único cluster (métricas internas no definibles, NaN documentado). Se selecciona $\varepsilon = 0{,}2$, $m = 5$: $k = 2$ y ruido $0\,\%$.

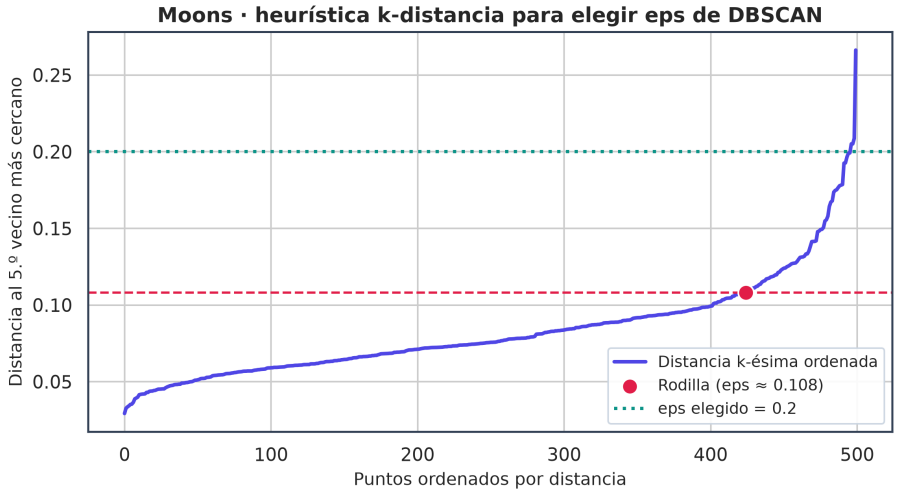


Figura VIII.1: Moons: curva k-distancia ($m = 5$) con la rodilla marcada en $\varepsilon \approx 0{,}108$. Fuente: notebook, celda 06.6.

Tabla VIII.1: Moons: barrido de DBSCAN con `min_samples`$= 5$.

ε	Clusters	Ruido	Ruido (%)	Silueta	Davies–Bouldin
0.08	19	91	18.2	0.244	0.796
0.10	6	37	7.4	0.199	1.080
0.12	2	20	4.0	0.329	1.155
0.15	2	2	0.4	0.326	1.161
0.18	2	1	0.2	0.327	1.159
0.20	**2**	**0**	**0.0**	**0.327**	**1.156**
0.25	2	0	0.0	0.327	1.156
0.30	1	0	0.0	—	—

8.2.3 Spectral Clustering

El barrido de la Tabla VIII.2 contrasta dos afinidades. Con RBF, la silueta *disminuye* al crecer γ: con γ pequeño el kernel es ancho y el corte espectral se parece al de K-means (particiones convexas "a lo largo" de las lunas, silueta 0.484); con γ grande el grafo captura la conectividad de cada luna y la partición se vuelve correcta, pero menos "convexa" (silueta 0.327). Con k vecinos, la partición es idéntica y robusta para 5, 10 y 15 vecinos; con 5 vecinos el grafo queda exactamente en dos componentes (las dos lunas: estructura ideal para el corte espectral) y con 10–15 vecinos el grafo se conecta pero el corte sigue siendo el correcto. Se selecciona kNN con 10 vecinos y $k = 2$: codifica directamente la conectividad de la variedad y no exige calibrar un ancho de banda.

Tabla VIII.2: Moons: barrido de Spectral Clustering ($k = 2$).

Afinidad	Grafo	Clusters	Silueta	Davies–Bouldin
RBF, $\gamma = 1$	Sí	2	0.484	0.789
RBF, $\gamma = 5$	Sí	2	0.476	0.809
RBF, $\gamma = 10$	Sí	2	0.412	0.923
RBF, $\gamma = 30$	Sí	2	0.327	1.156
RBF, $\gamma = 100$	Sí	2	0.327	1.156
kNN, 5 vecinos	No	2	0.327	1.156
kNN, 10 vecinos	**Sí**	**2**	**0.327**	**1.156**
kNN, 15 vecinos	Sí	2	0.327	1.156

8.3 Resultados

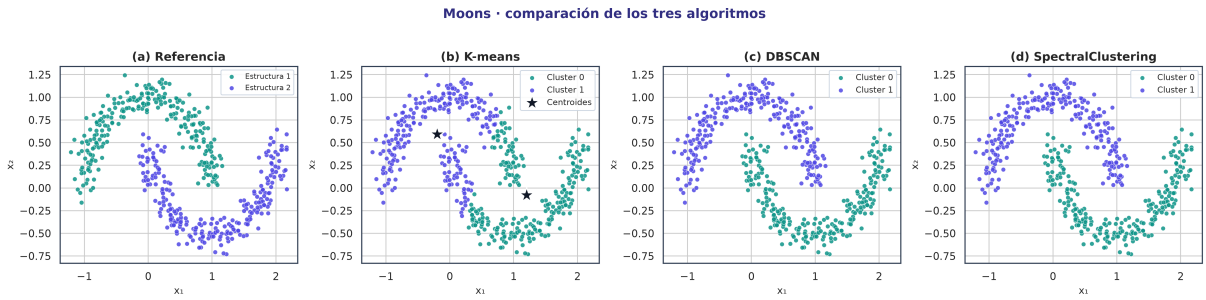


Figura VIII.2: Moons: referencia y particiones de los tres algoritmos. Fuente: notebook, celda 06.11.

Tabla VIII.3: Moons: métricas finales de los tres modelos.

Modelo	Configuración	k	Ruido	ARI	V-measure	Silueta	DBI
K-means	$k = 2$	2	0	0.265	0.202	**0.483**	**0.789**
DBSCAN	$\varepsilon = 0{,}2$, $m = 5$	2	0	**1.000**	**1.000**	0.327	1.156
Spectral	kNN, 10 vecinos	2	0	**1.000**	**1.000**	0.327	1.156

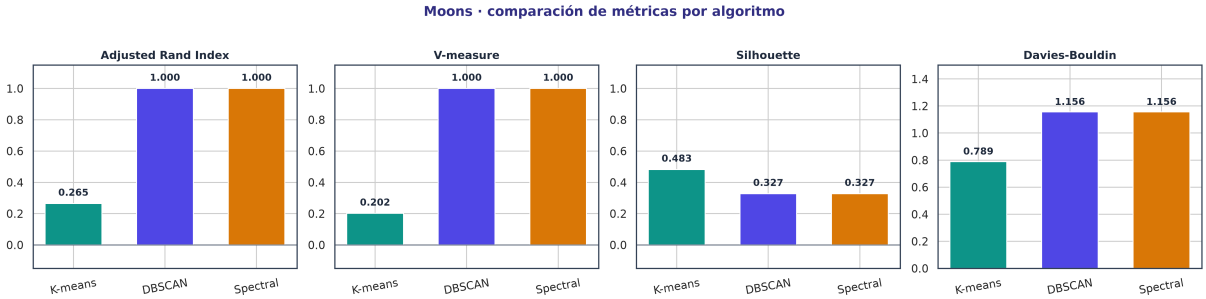


Figura VIII.3: Moons: métricas externas e internas de los tres modelos. Fuente: notebook, celda 06.12.

8.4 Análisis e interpretación

La Figura VIII.2 es inequívoca: K-means corta las lunas "por la cintura" en dos mitades convexas, mezclando puntos de ambas estructuras en cada cluster; DBSCAN y Spectral recuperan exactamente las dos lunas (ARI = V = 1.0, sin un solo punto mal asignado). La lectura más instructiva está en las métricas internas: la partición **incorrecta** de K-means obtiene la **mejor** silueta (0.483 frente a 0.327) y el **mejor** Davies–Bouldin (0.789 frente a 1.156) del experimento.

Sesgo de las métricas internas (hallazgo central)

En datos no convexos, la silueta y Davies–Bouldin premian la compactación y penalizan la forma alargada de las variedades correctas. Un analista que eligiera el modelo por silueta habría seleccionado la partición *equivocada*. Las métricas internas solo son confiables cuando la hipótesis geométrica del algoritmo coincide con la de la métrica; en datos no convexos deben complementarse con validación externa (cuando exista) o con diagnóstico visual y de dominio.

CAPÍTULO IX

EXPERIMENTO 3: TWO CIRCLES

9.1 Preparación y exploración

Two Circles contiene 500 puntos en dos anillos concéntricos (razón de radios 0,4, ruido $\sigma = 0{,}08$). Es el caso extremo de estructura no convexa: los dos grupos no solo no son separables linealmente, sino que **comparten centroide**, lo que anula cualquier criterio basado en centros. La Figura IX.2 (panel a) muestra la distribución original.

9.2 Desarrollo: calibración

9.2.1 K-means

Como en Moons, la mayor caída de inercia ocurre de $k = 1$ a $k = 2$ (293.8 → 192.1) y la curva se aplana: el codo indica $k = 2$, coherente con el generador. La silueta vuelve a preferir k mayores (0.410 con $k = 8$), por el mismo sesgo de convexidad ya documentado. Se entrena con $k = 2$.

9.2.2 DBSCAN

La rodilla k-distancia cae en $\varepsilon \approx 0{,}126$ (Figura IX.1). El barrido de la Tabla IX.1 replica el patrón de Moons con una particularidad: el anillo interior, al tener menor perímetro, es más denso que el exterior, por lo que existe una franja estrecha de ε que recupera los anillos (0.18–0.20) y una aún más estrecha que los funde. Con $\varepsilon = 0{,}2$, $m = 5$: $k = 2$, ruido 0 %, ARI $= 1{,}0$. Con $\varepsilon \geq 0{,}25$ todo el dataset colapsa en un cluster.

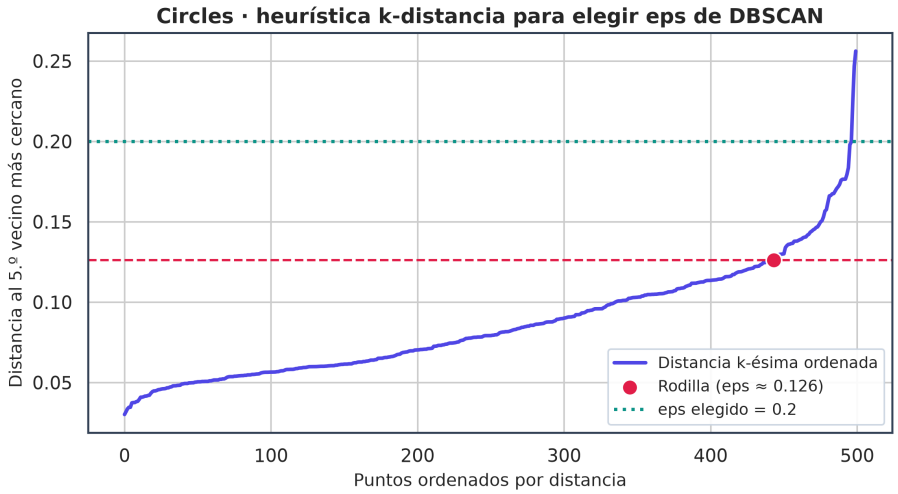


Figura IX.1: Circles: curva k-distancia ($m = 5$) con la rodilla marcada en $\varepsilon \approx 0{,}126$. Fuente: notebook, celda 07.6.

Tabla IX.1: Circles: barrido de DBSCAN con `min_samples`$= 5$.

ε	Clusters	Ruido	Ruido (%)	Silueta	Davies–Bouldin
0.08	15	174	34.8	0.292	0.506
0.10	18	70	14.0	0.277	0.594
0.12	7	15	3.0	0.283	0.777
0.15	3	3	0.6	0.090	36.75
0.18	2	1	0.2	0.152	180.19
0.20	**2**	**0**	**0.0**	**0.152**	**128.95**
0.25	1	0	0.0	—	—
0.30	1	0	0.0	—	—

9.2.3 Spectral Clustering

El barrido de la Tabla IX.2 replica la lección de Moons: con RBF y γ pequeño la partición se parece a la de K-means (silueta 0.328), y con $\gamma \geq 30$ o con afinidad de k vecinos el grafo captura la conectividad anular y la partición es la correcta (ARI $= 1{,}0$). La afinidad kNN es robusta para 5–15 vecinos y se selecciona de nuevo kNN con 10 vecinos y $k = 2$.

Tabla IX.2: Circles: barrido de Spectral Clustering ($k = 2$).

Afinidad	Grafo	Clusters	Silueta	Davies–Bouldin
RBF, $\gamma = 1$	Sí	2	0.328	1.220
RBF, $\gamma = 5$	Sí	2	0.329	1.215
RBF, $\gamma = 10$	Sí	2	0.327	1.218
RBF, $\gamma = 30$	Sí	2	0.152	128.95
RBF, $\gamma = 100$	Sí	2	0.152	128.95
kNN, 5 vecinos	No	2	0.152	128.95
kNN, 10 vecinos	**Sí**	**2**	**0.152**	**128.95**
kNN, 15 vecinos	Sí	2	0.152	128.95

9.3 Resultados

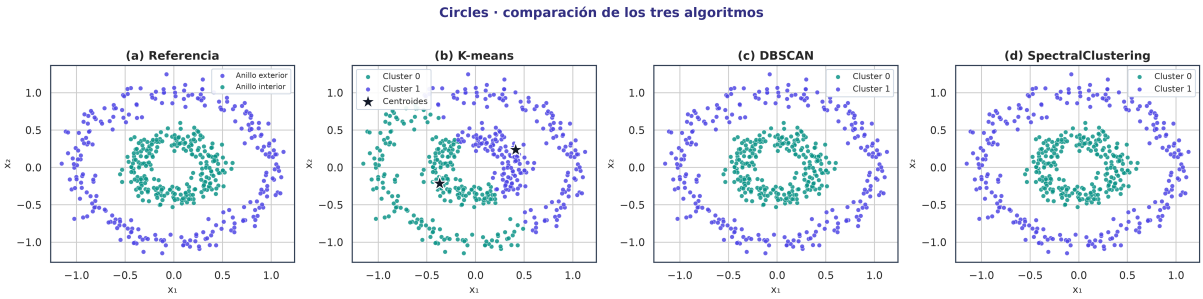


Figura IX.2: Circles: referencia y particiones de los tres algoritmos. Fuente: notebook, celda 07.11.

Tabla IX.3: Circles: métricas finales de los tres modelos.

Modelo	Configuración	k	Ruido	ARI	V-measure	Silueta	DBI
K-means	$k = 2$	2	0	$-0{,}002$	0.000	**0.328**	**1.221**
DBSCAN	$\varepsilon = 0{,}2$, $m = 5$	2	0	**1.000**	**1.000**	0.152	128.95
Spectral	kNN, 10 vecinos	2	0	**1.000**	**1.000**	0.152	128.95

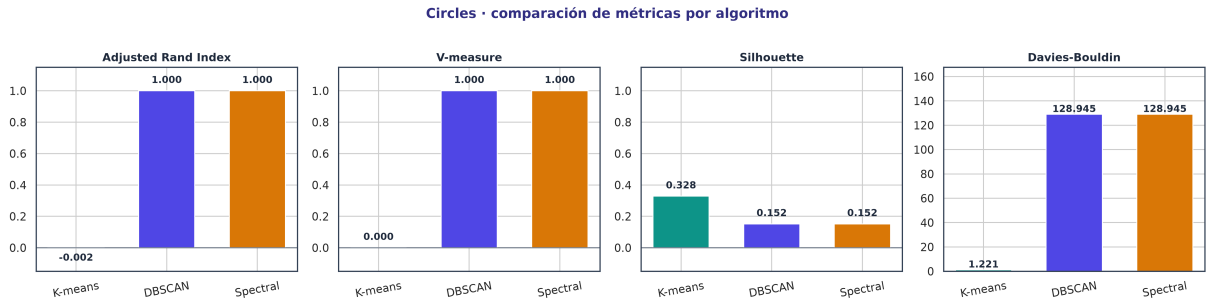


Figura IX.3: Circles: métricas externas e internas de los tres modelos. Fuente: notebook, celda 07.12.

9.4 Análisis e interpretación

K-means divide los anillos en dos "medias lunas" verticales: cada cluster contiene mitades de ambos anillos y el ARI resulta prácticamente nulo ($-0{,}002$: acuerdo peor que el azar tras el ajuste; V-measure 0.000). DBSCAN y Spectral recuperan la estructura exacta. El caso extremo lo protagoniza Davies–Bouldin: como ambos anillos comparten centroide, el denominador $\|\mu_i - \mu_j\|$ de la Tabla V.1 del Capítulo V tiende a cero y el índice explota a 128.95 para la partición *correcta*, frente a 1.221 para la incorrecta. La silueta repite el patrón de Moons (0.328 incorrecta frente a 0.152 correcta).

Lectura del experimento 3

En Circles el conflicto entre validez estructural y métricas internas es absoluto: la partición perfecta (ARI $= 1{,}0$) obtiene la **peor** silueta y un Davies–Bouldin dos órdenes de magnitud mayor que la partición errónea. Ninguna decisión razonada de clustering puede tomarse aquí solo con métricas internas.

CAPÍTULO X

COMPARACIÓN GENERAL DE LOS ALGORITMOS

10.1 Tabla consolidada

La Tabla X.1 consolida los nueve modelos finales; la Figura X.1 los compara gráficamente y la Figura X.2 resume el ARI por dataset y algoritmo.

Tabla X.1: Resumen general de los nueve modelos finales (semilla 42).

Dataset	Modelo	k	Ruido	ARI	V-measure	Silueta	DBI
Iris	K-means ($k = 3$)	3	0	0.620	0.659	0.460	0.834
Iris	DBSCAN ($\varepsilon = 0{,}7$)	2	6	0.540	0.671	0.602	0.557
Iris	Spectral (RBF $\gamma = 2$)	3	0	0.564	0.717	0.495	0.534
Moons	K-means ($k = 2$)	2	0	0.265	0.202	0.483	0.789
Moons	DBSCAN ($\varepsilon = 0{,}2$)	2	0	1.000	1.000	0.327	1.156
Moons	Spectral (kNN 10)	2	0	1.000	1.000	0.327	1.156
Circles	K-means ($k = 2$)	2	0	$-0{,}002$	0.000	0.328	1.221
Circles	DBSCAN ($\varepsilon = 0{,}2$)	2	0	1.000	1.000	0.152	128.95
Circles	Spectral (kNN 10)	2	0	1.000	1.000	0.152	128.95

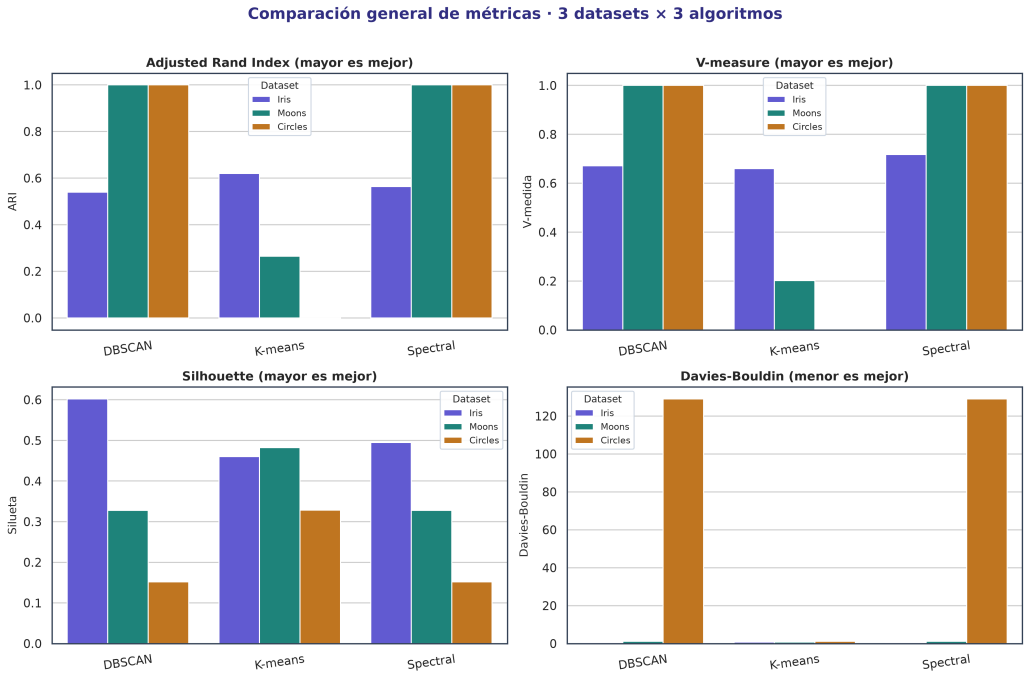


Figura X.1: Comparación general de métricas entre los tres algoritmos en los tres datasets. Fuente: notebook, celda 08.1.

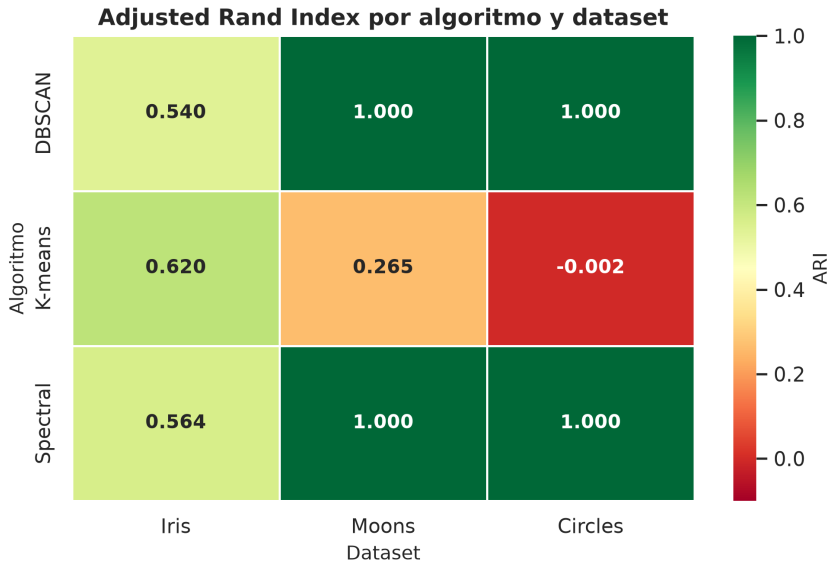


Figura X.2: Índice de Rand Ajustado por dataset y algoritmo. Fuente: notebook, celda 08.2.

10.2 Patrones observados

1. **No existe un algoritmo dominante.** En Iris, K-means y Spectral superan a DBSCAN en ARI; en Moons y Circles, DBSCAN y Spectral son perfectos y K-means falla. La elección correcta depende de la geometría, no de la "calidad" intrínseca del método.
2. **La caída de K-means es abrupta y estructural.** Su ARI pasa de 0.620 (Iris) a 0.265 (Moons) y a $-0{,}002$ (Circles) a medida que la convexidad desaparece: no es degradación gradual sino cambio de régimen.
3. **DBSCAN y Spectral son intercambiables en variedades.** En Moons y Circles ambos recuperan exactamente la estructura (ARI $= 1{,}0$) con hiperparámetros moderados; difieren en costo (DBSCAN es más barato) y en diagnóstico (DBSCAN detecta ruido; Spectral exige elegir afinidad).
4. **Las métricas internas invierten el ranking correcto en datos no convexos.** En Moons y Circles, la mejor silueta y el mejor DBI pertenecen a la partición errónea de K-means. En Iris, en cambio, DBSCAN lidera las internas con una partición razonable: el sesgo solo se manifiesta cuando la geometría lo activa.
5. **Las métricas externas concuerdan entre sí.** ARI y V-measure ordenan igual los nueve modelos; su desacuerdo con las internas es sistemático y está geométricamente explicado.

CAPÍTULO XI

ANÁLISIS DE MODELOS LINEALES Y NO LINEALES

11.1 Qué es "lineal" en clustering

Un modelo de clustering es lineal cuando la frontera entre clusters resultante es combinación lineal de las características: hiperplanos. K-means es lineal por construcción: su partición es el

diagrama de Voronoi de los centroides, una unión de celdas poliedrales. DBSCAN y Spectral Clustering son no lineales: sus fronteras emergen de la densidad local o de los cortes de un grafo y pueden adoptar cualquier forma.

11.2 Evidencia experimental

Los tres experimentos cuantifican la diferencia. En Iris, donde la separación dominante (*setosa* frente al resto) es aproximadamente lineal en el plano PCA, los tres algoritmos la capturan y las métricas externas quedan en una franja estrecha (ARI 0.54–0.62). En Moons, la frontera natural entre lunas es curva; K-means la aproxima con un hiperplano vertical que parte ambas lunas, mezclando estructuras (ARI 0.265). En Circles, la frontera natural es *topológica* (interior frente a exterior) y ningún hiperplano puede representarla: el ARI de K-means cae a $-0{,}002$, acuerdo nulo con la referencia.

11.3 Por qué los no lineales ganan en variedades

DBSCAN define pertenencia por caminos de densidad: recorrer una media luna es una secuencia de pasos cortos dentro de zonas densas, y la frontera entre lunas es la franja de baja densidad que las separa. Spectral Clustering codifica lo mismo en un grafo: con afinidad de k vecinos, cada luna (o anillo) es una cadena de aristas y el corte espectral solo tiene que separar dos componentes conectados. Ninguno de los dos usa centros, por eso compartir centroide (Circles) no los afecta. El costo de esa flexibilidad es doble: DBSCAN exige calibrar una escala de densidad global (ε) y Spectral paga un costo $O(n^2)$–$O(n^3)$ en memoria y tiempo por la descomposición espectral.

11.4 Guía de decisión práctica

Reglas extraídas de los experimentos

- Datos con grupos compactos y de escala similar (segmentación por comportamiento, cuantización): **K-means** es suficiente, rápido e interpretable.
- Grupos con formas arbitrarias, ruido presente o densidad roughly uniforme (geolocalización, segmentos espaciales): **DBSCAN**, calibrando ε con la curva k-distancia y vigilando el porcentaje de ruido.
- Estructuras de conectividad no espacial (similitud de grafos, comunidades): **Spectral Clustering** con afinidad kNN si se busca conectividad, RBF si se busca compactación en el espacio del kernel.
- En cualquier caso: validar con métricas externas si hay referencia, y desconfiar de la silueta/DBI cuando los grupos no sean convexos.

CAPÍTULO XII

HIPERPARÁMETROS CRÍTICOS Y LECCIONES DE CALIBRACIÓN

12.1 K-means: el número de clusters

k es obligatorio y no derivable de los datos sin criterio. El codo lo estimó correctamente en los tres datasets (3, 2 y 2), pero la silueta interna lo contradijo sistemáticamente ($k = 2$ en Iris, $k = 6$–8 en Moons y Circles), siempre en dirección de más convexidad. Lección: el codo más conocimiento de dominio es más confiable que la silueta para elegir k en presencia de geometría no convexa.

12.2 DBSCAN: ε y `min_samples`

ε fue el hiperparámetro más sensible de toda la actividad. La curva k-distancia situó la rodilla en 0.757 (Iris), 0.108 (Moons) y 0.126 (Circles), y los barridos mostraron tres regímenes: (i) ε por debajo de la rodilla fragmenta el dataset (19 clusters y 18 %de ruido en Moons con $\varepsilon = 0{,}08$); (ii) una banda de tolerancia por encima de la rodilla estabiliza la partición correcta (Moons y Circles se mantuvieron en $k = 2$ y ruido $\leq 4\,\%$ en $\varepsilon \in [0{,}12, 0{,}25]$ y $[0{,}18, 0{,}20]$ respectivamente); (iii) un umbral superior funde todo en un solo cluster. El porcentaje de ruido funcionó como termómetro operativo de calibración: la configuración óptima lo minimiza sin eliminarlo por completo. `min_samples` tuvo efecto secundario: subirlo de 5 a 10 en Moons requirió ε mayores y endureció la detección de frontera.

12.3 Spectral Clustering: afinidad y sus parámetros

La afinidad fue más determinante que el número de clusters. Con RBF, γ pequeño genera kernels anchos que "ven" blobs globales (particiones tipo K-means) y γ grande hace el grafo local y conserva la variedad; el cambio de régimen en Moons ocurrió entre $\gamma = 10$ y $\gamma = 30$. Con k vecinos, la partición fue robusta entre 5 y 15 vecinos en ambos datasets sintéticos. Lección: en variedades, la afinidad correcta es kNN y el riesgo principal de RBF es un γ que corta la variedad; en datos convexos, RBF con γ moderado (Iris: $\gamma = 2$) funciona bien. Verificar la conectividad del grafo antes de interpretar la partición es una buena práctica gratuita.

12.4 Sensibilidad resumida

La Tabla XII.1 ordena los hiperparámetros por impacto observado sobre el resultado.

Tabla XII.1: Sensibilidad observada de los hiperparámetros.

Hiperparámetro	Sensibilidad	Fallo típico observado
ε (DBSCAN)	Muy alta	Fragmentación con ruido masivo ($< 40\,\%$) o fusión total ($\geq 0{,}25/0{,}30$).
k (K-means)	Media	Sobre-fragmentación si se sigue solo la silueta ($k = 6$–8 en variedades).
γ (Spectral RBF)	Alta	γ pequeño: cortes convexos de la variedad; γ grande: grafo disconexo.
n vecinos (Spectral kNN)	Baja	Partición estable entre 5 y 15 vecinos en ambos datasets sintéticos.
`min_samples`	Media	Endurece la noción de núcleo y desplaza el ε óptimo.

CAPÍTULO XIII

CONCLUSIONES Y TRABAJO FUTURO

13.1 Conclusiones

1. **La geometría decide, no el algoritmo.** Sobre grupos convexos (Iris) los tres métodos producen particiones comparables (ARI 0.54–0.62); sobre variedades no convexas, la partición de K-means deja de ser válida de forma abrupta (ARI 0.265 en Moons, $-0{,}002$ en Circles) mientras DBSCAN y Spectral Clustering recuperan la estructura exacta (ARI $= 1{,}0$) en ambos.
2. **Las métricas internas tienen sesgo de convexidad.** En Moons y Circles la partición incorrecta de K-means obtuvo simultáneamente la mejor silueta y el mejor Davies–Bouldin. Elegir modelos por métricas internas en datos no convexos produce decisiones sistemáticamente erróneas.
3. **Davies–Bouldin es inaplicable a grupos concéntricos.** Al compartir centroide los dos anillos, el índice de la partición correcta explotó a 128.95 (frente a 1.221 de la errónea): una métrica basada en centros no puede evaluar una estructura que por definición carece de centros distinguibles.
4. **La validación externa es coherente y las internas divergen con ella exactamente cuando la geometría lo predice.** ARI y V-measure ordenaron los nueve modelos de acuerdo con su validez estructural; la silueta solo coincidió con ese orden en Iris.
5. **La calibración guiada por diagnóstico funciona.** La rodilla de la curva k-distancia situó ε dentro de la banda estable en los tres datasets (0.7, 0.2 y 0.2 finales frente a rodillas de 0.757, 0.108 y 0.126), y el porcentaje de ruido de DBSCAN resultó un indicador operativo simple de sobre- o sub-calibración.
6. **La afinidad es el hiperparámetro conceptual de Spectral Clustering.** kNN codifica conectividad (correcta para variedades) y RBF codifica cercanía global (adecuada para Iris); confundirlas produce particiones geométricamente coherentes con la afinidad equivocada, no errores aleatorios.
7. **En Iris, el desacuerdo moderado es información.** El solapamiento real entre *versicolor* y *virginica* fija un techo estructural al ARI; las diferencias entre algoritmos revelan estrategias distintas frente a la ambigüedad (corte de K-means, ruido de DBSCAN, recorte suave de Spectral).

13.2 Trabajo futuro

Quedan abiertas tres líneas inmediatas: extender la comparación a algoritmos con selección automática de escala (HDBSCAN, OPTICS) y a modelos generativos (mezclas gaussianas, que cuantifican la incertidumbre del solapamiento de Iris); estudiar el comportamiento en alta dimensión, donde la maldición de la dimensionalidad degrada tanto las distancias euclidianas como los grafos de similitud; y aplicar el protocolo a un dataset real institucional sin etiquetas,

donde el diagnóstico geométrico y las métricas de estabilidad (consenso, bootstrap) son las únicas herramientas disponibles.

REPOSITORIO DEL PROYECTO

Todo el material de la actividad —notebook, código fuente de este informe, resultados, figuras y tablas— se organiza para su publicación en un repositorio GitHub con la siguiente estructura:

Listing XIII.1: Estructura del proyecto.

```
Tarea 4/
|-- Actividad_04_Clustering.ipynb   # notebook ejecutado (61 celdas, 0 errores)
|-- main.tex                         # fuente de este informe
|-- Informe_Actividad_04.pdf         # informe compilado
|-- Logo_UNAP.png
|-- resultados/
|   |-- graficas/                    # 27 figuras PNG a 300 dpi
|   |-- metricas/                    # CSV de barridos y resumen por dataset
|   `-- tablas/                      # tablas consolidadas (resumen general)
`-- compilacion/                     # archivos auxiliares de LaTeX
```

El notebook es autocontenido y compatible con Google Colab: incluye una celda de instalación condicional de dependencias al inicio y usa rutas relativas para sus salidas, por lo que puede ejecutarse sin modificación en la nube o en local.

Enlace al repositorio

REFERENCIAS

[1] Davies, D. L. y Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-1(2), 224–227.

[2] Ester, M., Kriegel, H.-P., Sander, J. y Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96)*, 226–231.

[3] Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188.

[4] Hubert, L. y Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2(1), 193–218.

[5] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1, 281–297.

[6] Ng, A. Y., Jordan, M. I. y Weiss, Y. (2001). On spectral clustering: Analysis and an algorithm. *Advances in Neural Information Processing Systems 14 (NIPS 2001)*, 849–856.

[7] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[8] Rosenberg, A. y Hirschberg, J. (2007). V-measure: A conditional entropy-based external cluster evaluation measure. *Proceedings of the 2007 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning (EMNLP-CoNLL)*, 410–420.

[9] Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.

[10] von Luxburg, U. (2007). A tutorial on spectral clustering. *Statistics and Computing*, 17(4), 395–416.